

基于体素的 fMRI 数据分类研究及其应用

张 兵 董云云 邓红霞 李海芳*

(太原理工大学计算机科学与技术学院 山西 太原 030024)

摘 要 使用机器学习方法分类 fMRI (functional magnetic resonance imaging) 数据已经逐渐广泛被应用到探索大脑认知的研究中。在探索人脑视觉区域对颜色特征和形状特征的捆绑图像认知研究中,使用血氧含量水平 BOLD (blood oxygen level dependent) 最大值、BOLD 变化累计值作为特征值训练 SVM 分类器,使用 BOLD 变化时间序列方差及均值组合作为特征值训练多个 SVM 弱分类器,并使用 Adaboost 算法将多个 SVM 分类器集成到一起构造集成分类器,以此来判断人正在观察的图像的类型。实验结果表明,使用 BOLD 时间序列方差及均值组合作为特征构造的集成分类器分类正确率较高,对比不同视觉区域对特征捆绑任务识别正确率,发现 V3 区对图像复杂度的改变比较敏感,与特征捆绑的任务联系比较紧密。该方法可以应用到脑机接口 BCI (brain computer interface) 等领域。

关键词 SVM 分类 fMRI BOLD 变化模式 视觉区域 特征捆绑

中图分类号 TP399 文献标识码 A DOI:10.3969/j.issn.1000-386x.2015.02.035

RESEARCH AND APPLICATION OF VOXEL-BASED fMRI DATA CLASSIFICATION

Zhang Bing Dong Yunyun Deng Hongxia Li Haifang*

(College of Computer Science and Technology, Taiyuan University of Technology, Taiyuan 030024, Shanxi, China)

Abstract Using machine learning technology to classify fMRI (functional magnetic resonance imaging) data has been gradually and widely applied in the studies of exploring brain cognition. In the research of exploring the cognition of human brain visual area on the images hiding the colour and shape features, we use the maximum value of blood oxygen level dependent (BOLD) and the cumulative change value of BOLD as the eigenvalues to train SVM classifier, and use the combination of the variance and the mean of BOLD changes time series as the eigenvalue to train multiple SVM weak classifiers, furthermore, the Adaboost algorithm is employed to integrate multiple SVM classifiers to construct an ensemble classifier. With these it is able to determine the type of the images men are observing. Experimental result demonstrates that the ensemble classifier constructed using the combination of variance and mean of BOLD time series as the features has higher classification accuracy. Comparing the recognition accuracy of different visual areas on features binding task, it is found that the V3 area is sensitive to changes in image complexity and has closer links with the features-bound tasks. This method can be used to the field of brain computer interface (BCI), etc.

Keywords SVM classification fMRI BOLD change pattern Visual area Feature binding

0 引 言

颜色、大小、形状、空间位置等不同的属性构成了物体,大脑的不同区域加工不同的属性。为了把物体知觉成一个整体而不是零散的特征,需要把不同功能区的属性合理地整合到一起,这就是所谓的“特征捆绑”^[1]。特征捆绑是神经科学和认知科学研究的前沿问题之一。使用机器学习方法分类 fMRI 数据已经逐渐广泛被应用到探索大脑对特征捆绑图像认知的研究中。

功能性磁共振成像 fMRI 是近些年发展起来的一种新的成像技术,它可以检测出大脑认知状态的变化。fMRI 在脑认知研究和神经活动定位等方面具有很大的应用潜力^[2]。它的特点是 无创伤性、高空间和时间分辨率。血氧依赖水平 BOLD 法,作为目前应用最广泛的方法,其基础是根据神经元活动对脑血流和局部耗氧量影响程度的不同,当给于大脑刺激时,会改变局部

去氧一氧合血红蛋白的相对含量,引起磁场性质的变化,BLOD 法测量这种变化,产生大量的数据。研究者们通过分析这些数据推断大脑的认知状态。

目前 fMRI 主要应用在两方面:一种是脑功能定位的研究:一种是数据分类的研究。脑功能定位是探索任务状态下被激活的脑区,主要使用统计检验方法^[3]和数据挖掘方法^[4]。数据分类正好与脑功能定位研究的过程相反,主要是分析大脑不同的激活模式从而确定大脑当前所受到的刺激任务的类型,即大脑当前的认知状态^[5]。

模式识别方法和机器学习已广泛用于 fMRI 数据分类,探索大脑的认知状态。Kamitani 等人设计认知实验,刺激材料为多

收稿日期:2013-07-31。国家自然科学基金项目(61070077,61170136);山西省自然科学基金项目(2010011020-2)。张兵,硕士生,主研领域:智能信息处理,图像识别。董云云,硕士生。邓红霞,副教授。李海芳,教授。

角度的光栅,对被试进行视觉刺激,并分析得到的 fMRI 数据以此判断被试所受到的任务类型^[6]。Norman 等人采集任务态 fMRI 数据来训练 SVM 分类器,以此来判断被试看到的图片是物体还是人^[7],也可以判断被试正在观看的是鞋子还是瓶子^[8]。相杰等人使用全脑的体素做分类,成功预测了人脑所在执行的高级思维状态^[9]。Mitchell 等人对比研究了不同的分类算法^[10-13],主要对比了包括支持向量机 SVM、动态贝叶斯网络 DBNs (Dynamic Bayesian Networks)、高斯朴素贝叶斯 GNB (Gaussian Naive Bayes) 和 k2 最近邻分类算法 kNN (k2 Nearest Neighbor) 等。Mitchell 等人得出 SVM 解决小样本、非线性以及高维模式识别方面具有明显优势。

本文研究大脑视觉区域对颜色特征和形状特征的捆绑图像认知。首先介绍了实验设计与数据采集,然后介绍了几种常用的特征选择及特征抽取方法。对比显示基于单体素 BOLD 时间序列方差与均值组合的特征抽取方法的分类性能最好,并给出了与任务紧密联系的视觉区域及分类性能较好的 voxel 的坐标位置。

1 实验设计与数据采集

1.1 被 试

10 个健康的被试参加 fMRI 实验(5 女 5 男,平均年龄:24 岁,年龄范围:19~26 岁),没有精神疾病史。所有参与实验的被试都是右利手,被试视力均正常。实验前被试签署同意书。

1.2 扫描程序

1. 5T MR 扫描仪 Genmeny (Siemens Trio + tim) 核磁设备下进行结构像与功能像的扫描与采集,与 fMRI 配合的刺激任务由 E-Prime 2.0 软件控制,经投影仪投影到大屏幕,再由镜面反射映入人眼。结构像使用 T1 轴状序列,层厚度为 3.59 mm,进行全脑扫描时,平行前后联合水平,共计 28 层(AC-PC 位于从底层到顶层第 9 层);功能像使用单次激发回波平面成像 SS-EPI (Single Shot Echo Planar Imaging) 序列,扫描参数如:FOV = 230 mm,TR = 2000 ms,TE = 31 ms,Flip Angle = 90。Slice thickness = 3.59 mm,Disp Factor = 0%,Resolution = 64 × 64,采集方位与结构像相同。

1.3 实验任务

本文的认知实验,采用简单的几何图形作为刺激任务,每个图片具有两种基本特征——颜色与形状,颜色有三种红色、蓝色、绿色,形状也有三种,包括三角形、方形与圆形。本实验设计了 4 种类型的任务,每种任务为两张图片的对比:任务 1:颜色与形状都相同;任务 2:形状不同颜色相同;任务 3:形状相同无颜色;任务 4:颜色不同形状相同。4 种任务的对比图像示例如图 1 所示。




图 1 任务图像

图像刺激过程如图 2 所示,刺激开始时屏幕正中央呈现一个“+”符号,时长 4 s,然后随机显示任务 1、2、3、4 这四种任务中的一种,显示时长为 4 s,然后选择按键,要求根据任务的类型选择按键,按键后闭眼休息 8 s 等待下一个任务出现。本实验

总共 32 个任务(每种类型有 8 个任务),每个任务被随机排列。任务总共时长 512 s。图 2 为图像刺激过程。

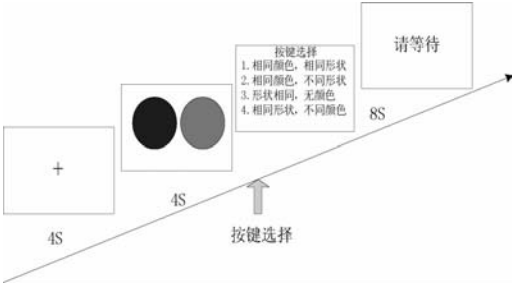


图 2 图像刺激过程

针对特征捆绑的任务,实验设计时,任务 1 和任务 3 中对比的两幅图像的特征相同,只考虑单特征对脑认知的影响。任务 1 中对比的两幅图像形状与颜色都相同,任务 3 中对比的两幅图像形状相同,无颜色。任务 2 和任务 4 中涉及形状和颜色两种特征的对比,即考察双特征对脑认知的影响。任务 2 中对比的两幅图像颜色不变,形状改变,任务 4 中对比的两幅图像形状没有变化,颜色改变。

1.4 数据预处理

进行实验时,被试不可避免会有头动发生,所以使用 SPM 软件进行头动矫正、标准化、平滑等预处理。分类实验中使用了 10 个被试的数据。

2 相关方法

2.1 特征选择

fMRI 机器在相等的时间间隔内按照一定的空间分辨率对大脑进行重复性的扫描,形成一个数据文件。数据中的每一个元素都称为一个 voxel,元素的值为该 voxel 的 BOLD 变化值。若按 voxel 的体积 3 mm × 3 mm × 3 mm 来计算,人脑大约有 10 000 ~ 15 000 个这样的 voxel。直接使用所有 voxel 来训练分类器就会造成一个高维空间。对于这种高维空间,即使具有上百个样本数据的训练集也是非常稀疏的。为了确保分类器具有较高分类正确率和训练效率,选择适当的特征是很有必要的。目前,基于 fMRI 数据分类研究常用的特征选择方法有以下几种:

(1) 根据单个 voxel 的分类情况,选择并集成分类正确率较高的 voxel。

(2) 根据大脑功能区划分的相关理论,选取与任务相关的脑区的 voxel。研究认知神经科学发现,大脑是由多个不同功能区组成,认知过程是由多个功能区域协同完成的。如视觉皮层和视觉有关,额叶皮质负责处理思考、运动皮质控制活动。Has-son 在研究映入眼帘的是人还是物体时,选择大脑视觉区域的 voxel 作为特征的。

(3) 如图 3 所示,选择激活的 voxel。当大脑受到任务刺激时,相关脑区的血氧消耗量明显增多,相对于静息态的基线水平,若某些 voxel 的血氧增加量超过一定的阈值,则认为该 voxel 是激活的,选择这些体素作为特征分类 fMRI 数据。




图 3 体素采样

(4) 选取全脑的所有 voxel,运用主成分分析 PCA (principal component analysis) 方法进行降维。Naselaris 等人曾经选取这种方法研究认知状态的分类。

在这些研究的基础上,本文选择对比了两种方法。第一种,选择视觉区域的激活 voxel;第二种,选取了视觉区域的所有体素作为研究对象,对这些体素进行单体素训练,筛选分类效果较好的单 voxel 并通过 Adaboost 算法集成得到分类结果。

2.2 特征抽取

经过特征选择之后,体素的个数减少了,但是如果将每一个任务作为一个训练样本的话,数据的维数将非常大,这对于后面数据进行分类是非常困难的。因此在分类之前,首先要对数据进行特征抽取,降低数据维数。本文所采用的特征抽取都是基于 BOLD 效应的,从 BOLD 效应中提取所需的特征。现有的 fMRI 数据分类研究中,主要采用以下特征抽取方法:

- (1) BOLD 变化率的最大值:一组任务中,BOLD 变化率最大值。如图 4 所示。
- (2) BOLD 变化速度:即经过多长时间达到最大值或需要经过多长时间由峰值降低到基线水平。如图 5 所示。
- (3) BOLD 变化率的累计值:在一组任务中,所有 BOLD 变化率的总和。如图 6 所示。




图4 BOLD 变化最大值




图5 BOLD 变化速度




图6 BOLD 变化累计值

2.3 分类算法

本文采用了 SVM 分类算法。
Vapnik 等人在多年研究统计学习理论的基础上提出了支持向量机 SVM 方法,它在解决小样本、非线性以及高维模式识别方面具有明显优势,并能够使用在其他机器学习问题中,可

以推广应用到函数拟合等问题。

SVM 分类算法是通过一个非线性映射 p ,把样本空间映射到一个高维空间中 (Hilbert 空间),把将在原先空间中的线性不可分问题转化为在特征空间中的线性可分问题,即升维和线性化。

SVM 算法的参数设置尤为重要,这关系到分类效果的好坏。实验采用基于 Matlab 平台 Lib-SVM 工具包,在训练过程中,核函数采用 RBF ,参数 c (cost)取 1, g (gamma)取 1。实验中,利用网格参数删选法,步长为 0.05,得出:对于相同的训练集和测试集,当参数 c 取值为 0.35 到 0.85 之间的数,分类结果明显好于 c 取值为 -1 到 1 之间其他的数。并且当 c 和 g 同取 0.4 到 0.75 之间的不同数值时,分类正确率差别不大。SVM 实验流程如图 7 所示。

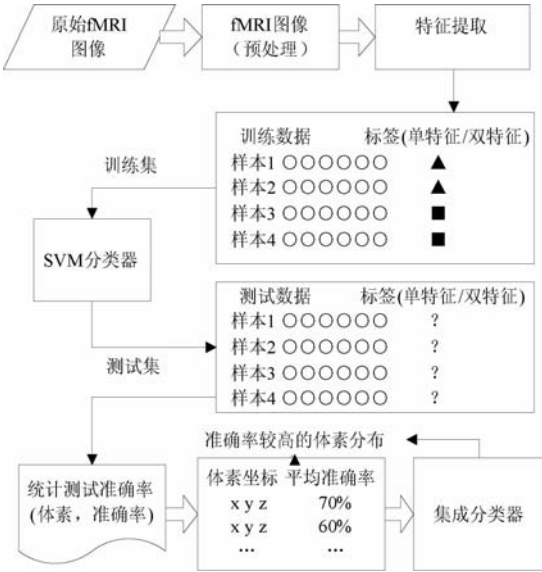


图7 SVM 数据分类实验流程图

2.4 分类器集成

个体分类器分类效果取决于特征选择,在模式识别中,通常具有多个特征,如果这些特征之间差别比较大,那么很难将它们集成到单一分类器中进行决策。另外,由于受到函数参数选择、样本噪声干扰等诸多方面因素的影响,个体分类器的分类性能会降低。所以,我们采用多分类器集成来克服这个弱点。

根据弱学习理论,将多个分类准确率不高的分类器加权组合,可以构成分类准确率更高的集成分类器。常用的算法为 Bagging (Bootstrap AGGREGatING) 算法和 Adaboost 算法,通过加权投票方式将多个弱分类器集成,构造集成分类器^[14]。

本文选择了 Adaboost 算法将多个 SVM 分类器集成到一起 (Adaboost-SVM),既将单体素分类正确率较高的体素集成在一起构成一个训练样本空间,对这个样本空间训练成不同的 SVM 分类器 (弱分类器),然后将这些弱分类器根据其分类正确率的大小赋予不同的权值,然后加权集成,进一步提高分类器的分类精度。

3 实验与结果分析

采用 10 折交叉验证的方法来验证分类器的性能。实验数据包括 10 个 session,轮流将其中的 9 份做训练 1 份做测试,9 次的结果的均值作为对算法精度的估计。

3.1 使用激活区 BOLD 变化率最大值作为特征的分类结果

提取 V1 区中激活 voxel 的 BOLD 累积变化值形成 n 维输入向量 $V = [v_i] = (v_1, v_2, \dots, v_n)$, 其中 v_i 是 V1 激活。

区域中的第 i 个 voxel 在某个任务中的 BOLD 变化率的最大值。一个任务对应的向量连同该任务的任务类型标签形成一个训练样本,用于训练 SVM 得到一个 SVM 分类器。

图 8 是使用 V1 区激活 voxel 的 BOLD 变化率最大值作为特征进行 fMRI 分类的正确率。该结果是使用特定被试的样本训练好的分类器预测该被试完成的其他任务的任务类型的正确率。结果表明所有被试的分类器正确率均高于随机水平,其平均正确率为 61.5%。




图 8 基于激活区域 BOLD 最大值特征的分类正确率

3.2 使用 BOLD 激活区变化率累计值作为特征的分类结果

提取 V1 区中激活 voxel 的 BOLD 累积值形成 n 维输入向量 $V = [v_i] = (v_1, v_2, \dots, v_n)$, 其中 v_i 是 V1 激活区域中的第 i 个 voxel 在某个任务中的 BOLD 变化率的最大值。一个任务对应的向量连同该任务的任务类型标签形成一个训练样本,用于训练 SVM 得到一个 SVM 分类器。

图 9 是 V1 区激活 voxel 的 BOLD 变化率累计值作为特征进行 fMRI 分类的正确率。该结果是使用特定被试的样本训练好的分类器预测该被试完成的其他任务的任务类型的正确率。结果表明所有被试的分类器正确率均高于随机水平,其平均正确率为 61.125%。




图 9 基于激活区域 BOLD 累计值特征的分类正确率

3.3 使用单体素 BOLD 时间序列方差及其均值作为特征的分类结果

如图 10 所示,提取 V1 区任务时 voxel 的 BOLD 时间序列的方差值与均值,构成 2 维输入向量 $T = [C_j] = (c_1, c_2)$, 一个任务对应的向量连同该任务类型标签形成一个训练样本,用于训练得到一个 SVM 分类器,选择并集成单体素分类正确率大于 60% 的体素,组成一个训练样本空间。对这个样本空间训练成不同的 SVM 分类器(弱分类器),然后将这些弱分类器根据其分类正确率的大小赋予不同的权值,然后加权集成,进一步提高

分类器的分类精度。




图 10 单体素 BOLD 时间序列方差及均值构成的样本序列

图 11 是使用 V1 区单 voxel 分类正确率较高的体素的 BOLD 时间序列方差及其均值作为特征进行 fMRI 分类的正确率。结果表明所有被试的分类器正确率均高于随机水平,其分类正确率可以达到 78.75%,可以看出使用 BOLD 时间序列方差值及其均值作为特征构造的 Adaboost—SVM 分类器分类效果显著优于分别使用激活区域的 BOLD 最大变化值和 BOLD 累计变化值作为特征的分类效果。




图 11 基于 BOLD 时间序列方差及均值组合特征的分类正确率

3.4 使用 3.3 中提到的方法对初级视觉区域 V1、V2、V3、V4 区分类

如图 12 – 图 15 所示是使用 Adaboost 算法对 V1、V2、V3、V4 做分类时得到的分类准确率变化图像。从图可知,当迭代次数超过 12 次后,分类正确率趋于平稳,对比可知,基于 V3 区单体素所集成分类器对任务的正确识别率高达 91.5%。这些体素分布如表 1 所示。




图 12 V1 区 Adaboost 算法分类准确率变化图




图 13 V2 区 Adaboost 算法分类准确率变化图

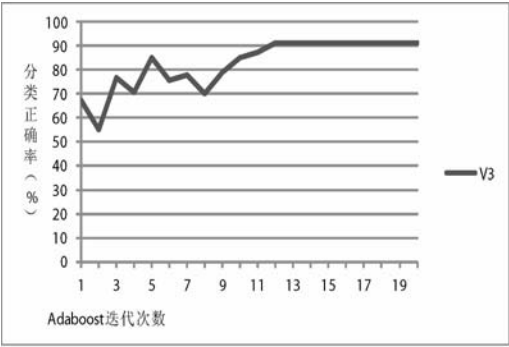


图 14 V3 区 Adaboost 算法分类准确率变化图




图 15 V4 区 Adaboost 算法分类准确率变化图

表 1 与任务紧密相关的体素分布

X	Y	Z	平均正确率
-18	-64	-24	74.25%
-45	-66	-21	78.15%
-18	-63	-21	75%
-12	-51	-12	81.625%
-42	-69	-6	75.125%
-48	-72	-6	78.5%
-24	-51	0	73.25%
-45	-81	9	72%
-39	-25	12	78.15%
-21	-84	21	80.625%
-6	-82	27	75%
36	-78	30	71.75%
-15	-84	33	76.125%

本文研究表明视觉区域保留一些视觉特征信息,这些信息可以直接反应大脑的部分记忆内容,视觉区 V3 区域对颜色特征和形状特征捆绑的图像比较敏感。在另一个研究中,Harrison 和 Tong 也指出初级视觉区域可以保留一些视觉特征信息,这些信息可以直接反应出大脑的部分记忆内容,他们指出线条朝向表征与 V1 区的联系更为紧密^[15]。这些研究表明:视觉区域在大脑对图像特征的识别中起着重要作用。

4 结 语

本文从数据分类的角度出发,对比了不同的特征选择和特征值提取方法,得出了以单个体素的 BLOD 时间序列的方差值和均值作为分类特征,可以更好地分类 fMRI 数据。除此之外,通过对比不同视觉区域单体素集成分类器的正确率,可以发现与任务关系密切的区域。与传统的统计分析方法不同,该方法可以发现统计差异不明显但确实参与了任务的脑区体素,所以,该方法可以作为传统 fMRI 数据分析方法的补充。可以为利用 fMRI 实现 BCI (脑机接口)提供方法。

参 考 文 献

[1] 李海芳,尹清. 视觉感知中特征捆绑建模方法的研究[J]. 计算机工程,2011,37(22) :151 - 155.

[2] Jiang W, Liu H. A functional MRI study of deception among offenders with antisocial personality disorders [J]. Neuroscience, 2013, 244: 90 - 98.

[3] Xiaomin Yue, Shahin Nasr. FMRI analysis of contrast polarity in face-selective cortex in humans and monkeys[J]. NeuroImage, 2013, 76: 57 - 69.

[4] Tomberg T, Braschinsky M. Functional MRI of the cortical sensorimotor system in patients with hereditary spastic paraplegia[J]. Spinal Cord, 2012, 50: 885 - 890.

[5] Hall M H, Smoller J W. Patterns of deficits in brain function in bipolar disorder and schizophrenia: A cluster analytic study[J]. Psychiatry research, 2012, 200: 272 - 280.

[6] Kamitani Y, Tong F. Decoding the visual and subjective contents of the human brain[J]. Nature Neuroscience, 2005, 8: 679 - 685.

[7] Norman K A, Polyn S M. Beyond mind reading: Multi-voxel pattern analysis of fMRI data[J]. Trends in Cognitive Sciences, 2006, 10(9) : 424 - 430.

[8] Haxby J V, Gobbini M I, Furey M L, et al. Distributed and overlapping representations of faces and objects in ventral temporal cortex[J]. Science, 2001, 293: 2425 - 2430.

[9] 相洁. 基于 SVM 的 fMRI 数据分类: 一种解码思维的方法[J]. 计算机研究与发展, 2010, 47(2) : 286 - 291.

[10] Banerjee T P, Das S. Multi-sensor data fusion using support vector machine for motor fault detection[J]. Information Sciences, 2012, 217: 96 - 107.

[11] Santos Jr E, Li D. Temporal Bayesian Knowledge Bases-Reasoning about uncertainty with temporal constraints[J]. Expert Systems with Applications, 2012, 39(17) : 12905 - 12917.

[12] de Moraes R M, dos Santos Machado L. Online Assessment in Medical Simulators Based on Virtual Reality Using Fuzzy Gaussian Naive Bayes [J]. Multiple-Valued Logic and Soft Computing, 2012, 18(5 - 6) : 479 - 492.

[13] Park H S, Cho S B. Evolutionary attribute ordering in Bayesian networks for predicting the metabolic syndrome[J]. Expert Systems with Applications, 2012, 39(4) : 4240 - 4249.

[14] Schwenk H, Bengio Y. Boosting neural networks[J]. Neural Computation, 2000, 12(8) : 1869 - 1887.

[15] Harrison S A, Tong F. Decoding reveals the contents of visual working memory in early visual areas [J]. Nature, 2009, 458 (7238) : 632 - 635.